2. Hands-On Orquestração

Deploy do Airflow via Helm Chart + ArgoCD

Criar Minikube Adequado p/ Teste

Vamos configurar um novo minikube com mais potência pra esse teste:

minikube start -p testeAirflow --driver=docker --cpus=4 --memory=6152

Add Repo Oficial Helm Chart + Instalação Default

Vamos adicionar o repositório helm e ver um comando de instalação default

- helm repo add apache-airflow https://airflow.apache.org/
- helm install my-airflow apache-airflow/airflow --version 1.15.0

Estrutura do Airflow Utilizado como Guia:

Versão: 2.9.3

Versão Helm Chart: 1.15.0 (02/12/24)

executor: Kubernetes Executor ou Celery Executor

gitSync: Repo no GitHub com subpasta

Conexão: ssh com chave privada

Banco Metadata: Postgres local

Imagem Customizada: Não

Logs Remotos: Sim

Dentro do Minio: Sim

Configuração SMTP: Não (apenas guia)

Nos próximos passos abaixo vamos adequar o manifesto para instalar o Airflow de maneira dinamica via ArgoCD:

Configuração do Executor

Ideal para o Minikube: LocalExecutor OU LocalKubernetesExecutor

Ideal para clusters na nuvem: KubernetesExecutor

Adequar serviço SMTP da sua escolha

No values.yaml do Airflow, preencher os parâmetros abaixo caso queira receber notificações por email:

```
#- name: AIRFLOW__LOGGING__REMOTE_TASK_HANDLER_KWARGS
# value: '{"delete_local_copy": true}'
#- name: AIRFLOW__SMTP_SMTP_HOST
# value: 'smtp.office365.com'
#- name: AIRFLOW__SMTP_SMTP_PORT
# value: '587'
#- name: AIRFLOW__SMTP_STARTTLS
# value: 'True'
#- name: AIRFLOW__SMTP_SSL
# value: 'False'
#- name: AIRFLOW__SMTP__SMTP_MAIL_FROM
# value: ''
#- name: AIRFLOW__SMTP__SMTP_USER
# value: ''
#- name: AIRFLOW__SMTP__SMTP_PASSWORD
# value: ''
```

Adequar login e senha das aplicações

```
# Create initial user.
 defaultUser:
   enabled: true
   role: Admin
   username: admin
   email: admin@example.com
   firstName: dataway
   lastName: br
   password: Za9W0bt
postgresql:
 enabled: true
 auth:
   enablePostgresUser: true
   postgresPassword: postgres
   username: ""
   password: ""
```

Criar secret a partir da chave SSH do Github (local das dags)

A secret deve ser com base na chave ssh privada (mesma utilizada pelo ArgoCD). Transformar a chave ssh em base64 encoded:

• openssl base64 -in .\gitAirflow -out gitAirflowencoded.txt

Desabilitar Hooks e CustomEnvs para o ArgoCD

Link documentação: https://airflow.apache.org/docs/helm-chart/stable/index.html#installing-the-chart-with-argo-cd-flux-rancher-or-terraform

Editar na seção migrateDatabaseJob e createUserJob:

```
useHelmHooks: falseapplyCustomEnvs: false
```

Sem essas opções somente a instalação manual via Helm vai funcionar, pelo ArgoCD entrará em loop infinito sem conseguir criar o init-container wait-for-airflow-migrations

Logs Remotos com Minio

Para salvar os logs de maneira histórica dentro do Storage e os logs dentro do Airflow acabarem sumindo, é necessário ativar o Log Remoto e salvar em arquivos .log dentro de um bucket.

Processos necessários:

- Acessar o console do MinIO
 - minikube service dlkdataway-console -n storage -p testeAirflow
- Endereço de Endpoint do MinIO
 - { "endpoint_url": "http://dlkdataway-hl.storage.svc.cluster.local:9000" }
- Minio Keys:
 - Access Key: erAPAmQGNIS3dAb16S0p
 - Secret Key: yJxoNbQMMWJsqOwSJ1PNMYKn3vfRPq9MLy8ClHGk
- Airflow Connection

Add Connection	
Connection Id *	minio_s3_conn
Connection Type *	Amazon Web Services Connection Type missing? Make sure you've installed the corresponding Airflow Provider Package.
Description	Conexao para salvar os logs remotos das dags executadas dentro do bucket do Minio airflow-log
AWS Access Key ID	erAPAmQGNIS3dAb16SOp
AWS Secret Access Key	
	{ "endpoint_url": "http://dlkdataway-hl.storage.svc.cluster.local:9000" }

Edição dentro do values.yaml do Airflow

```
logging:
    # Opcoes para logs remotos dentro do Minio via S3
    #remote_logging: '{{- ternary "True" "False" .Values.elasticsearch.enabled
}}'
    remote_logging: 'True'
    colored_console_log: 'False'
    # bucket dentro do minio
    remote_base_log_folder: 's3://airflow-logs'
    # nome da conexao do tipo amazon web services dentro do Airflow
    remote_log_conn_id: minio_s3_conn
    encrypt_s3_logs: False
```

Dentro do bucket do MinIO, é criada a hierarquia:

- dag_id=nome-dag
 - task id=nome-task
 - arquivo.log
- O log é criado próximo de finalizar a execução da dag, onde o log é exportado pra o local

Com o tempo, o Airflow vai eliminando os logs da interface.



Instalação via ArgoCD

Criação da aplicação na pasta do repositório:

```
apiVersion: argoproj.io/v1alpha1
kind: Application
metadata:
  name: airflow-datawaybr
  namespace: argocd
spec:
  project: default
  source:
    repoURL: 'git@github.com:Alexno9/k8s-argo-minio.git'
    path: helm-chart/airflow
    targetRevision: main
    helm:
      valueFiles:
        - values.yaml
  destination:
    server: 'https://kubernetes.default.svc'
    namespace: orchestrator
  syncPolicy:
    automated:
      prune: true
      selfHeal: true
```

Pós Instalação - Permissão entre Airflow & Spark Operator

```
apiVersion: rbac.authorization.k8s.io/v1
kind: ClusterRoleBinding
metadata:
   name: airflow-datawaybr-scheduler
```

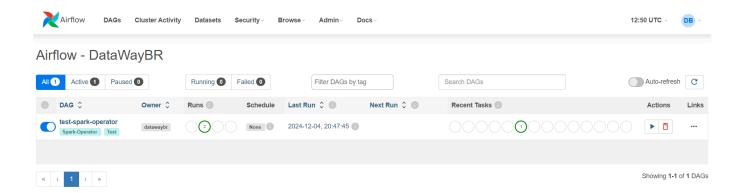
namespace: orquestrator
subjects:
 - kind: ServiceAccount
 name: airflow-datawaybr-scheduler
 namespace: orquestrator
roleRef:
 kind: ClusterRole
 name: cluster-admin
 apiGroup: rbac.authorization.k8s.io

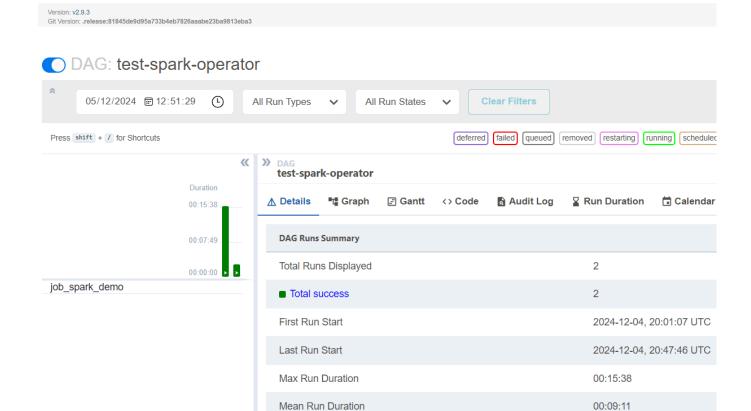
Pós Instalação - Airflow Connection Kubernetes

- Navegar até Connections
- Criar uma nova no símbolo +
- Escolher a conexão do tipo Kubernetes Cluster
- Marcar a opção in cluster configuration
- No campo namespace, colocar o namespace do Spark Operator
- Salvar

Edit Connection kubernetes_minikube_conn Connection Id * **Kubernetes Cluster Connection** Connection Type * Connection Type missing? Make su Description </ In cluster configuration Kube config path Kube config (JSON format) operator Namespace

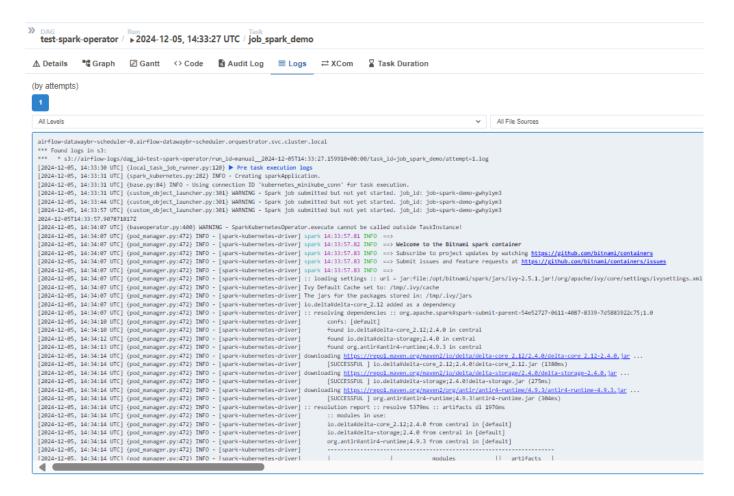
Airflow UI





00:02:44

Min Run Duration



Deploy do Airflow com Logs no Azure Storage Account

Build da Imagem Docker com Airflow customizado

A imagem customizada uma padrão do Airflow para ter as libs python do seu projeto + arquivo de config local que permite salvar os logs dentro da Azure (AWS s3 já é nativo):

```
RUN rm -rf /var/lib/apt/lists/*
USER airflow
RUN pip install --no-cache-dir -r /requirements.txt
```

Com a imagem dentro do DockerHub, devemos cadastra-la no values.yaml do Airflow:

```
# Images
images:
    airflow:
       repository: alexno9/airflow-custom
       tag: v01
    # Specifying digest takes precedence over tag.
    digest: ~
    pullPolicy: IfNotPresent
```

Adequar local externo de armazenamento de logs

Preenchendo os valores abaixo, o Airflow substitui dentro do arquivo airflow.cfg. Valores para salvar em blob storage da Azure:

```
logging:
    #remote_logging: '{{- ternary "True" "False" .Values.elasticsearch.enabled
}
}'
    base_log_folder: '/opt/airflow/logs'
    remote_logging: 'False'
    remote_base_log_folder: 'wasb://logs-
airflow@staccdatawaybrlogs.blob.core.windows.net/logs'
    remote_log_conn_id: 'azure_blob_storage_logs'
    delete_local_copy: 'False'
    colored_console_log: 'False'
```

Comunicação de Todo Ambiente

Utilização de Cluster na Azure Cloud

Para aproveitarmos todo o potencial de todo o ambiente em conjunto, iremos construir as nossas aplicações dentro da nuvem Azure.

- Criação de Resource Group
- Criação de Storage Account
- Criação de Cluster AKS

MinIO

- Logar no ambiente: minikube service dlkdataway-console -p testeJupyter -n storage
- Access Key ID: erAPAmQGNIS3dAb16SOp
- Access Secret Key: yJxoNbQMMWJsqOwSJ1PNMYKn3vfRPq9MLy8ClHGk
- Utilizar os buckets criados para simular um código spark que leia e grave os dados delta nos buckets
- kubectl create secret generic minio-s3-credentials -n operator --from-literal=AWS_ACCESS_KEY_ID=erAPAmQGNIS3dAb16SOp --from-literal=AWS_SECRET_ACCESS_KEY=yJxoNbQMMWJsqOwSJ1PNMYKn3vfRPq9MLy8ClHGk

Airflow DAG

Rodas a dag-minio-delta-tables para simular leitura e tratamento de dados no storage